

APLICAÇÃO DA METAHEURISTICA ALGORITMO GENÉTICO NA OTIMIZAÇÃO DE PROBLEMAS COM MÚLTIPLAS RESPOSTAS.

Fabricio Maciel Gomes (EEL/USP)

fmgomes@usp.br

Felix Monteiro Pereira (EEL/USP)

felix@dequi.eel.usp.br

Messias Borges Silva (EEL/USP)

messias@dequi.eel.usp.br

Fernando Augusto Silva Marins (UNESP)

fmarins@feg.unesp.br



Este trabalho apresenta um estudo comparativo entre a metodologia de otimização desirability e a utilização do algoritmo genético na otimização de processos com múltiplas respostas. Na estimativa dos parâmetros que minimizam a função objetivo, considerou-se as respostas geradas pela técnica do planejamento de experimentos de forma aglutinada, que foram incorporadas à função objetivo ou função desejabilidade global obtida pelo método desirability. Na otimização dos valores dos parâmetros do processo foi utilizado o algoritmo genético, presente na função optim_ga do software computacional Scilab. Foram realizadas 10 replicações e calculada a média dos resultados obtidos. Para se proceder a uma comparação entre os métodos numa base equitativa, dado que a função utilidade global não tem a mesma forma para ambos, o desempenho dos métodos foi avaliado com base em medidas de desempenho, por meio da distância absoluta e distância percentual. Considerando as medidas de desempenho utilizadas, o algoritmo genético apresentou melhores resultados em comparação com o método desirability, o que indica que o AG tem a vantagem de otimizar todas as respostas de maneira equilibrada, podendo gerar respostas melhores que a abordagem mais simples utilizando desirability.

Palavras-chave: Algoritmo Genético, Desirability, Otimização

1. Introdução

Diferentes áreas do conhecimento possuem como um de seus objetivos analisar e resolver problemas envolvendo respostas múltiplas (COSTA e PIRES, 2007; XU *et al.*, 2004). Para resolver estes tipos de problemas, é necessário modelar cada uma das respostas a serem otimizadas por uma função que descreva uma Superfície de Resposta, ou seja, que permita estimar o valor da resposta dentro do intervalo de variação definido para as variáveis em estudo. Essas funções são normalmente obtidas por regressão múltipla dos resultados de experimentos desenhados pelo modelo de Box-Behnken, Compósito Central ou de desenhos fatoriais a três níveis sendo, em geral, equações de segunda ordem. Esses modelos foram caracterizados por Wu e Hamada (2000), que afirmam que o modelo Compósito Central (CCD – *Composite Central Design*) é o mais utilizado.

Usualmente, em estudos de otimização envolvendo um pequeno número de respostas e de variáveis, utiliza-se a sobreposição dos gráficos da superfície de cada uma das respostas a fim de se identificar, por simples observação, os valores das variáveis que permitirão alcançar os melhores resultados nessas respostas (CARLILE *et al.*, 2000). Porém, esta prática não é recomendada para um número maior de variáveis e/ou respostas sendo, nestes casos, necessário utilizar um algoritmo de otimização para determinar o valor das variáveis que permita encontrar o melhor compromisso entre os valores das respostas (SOUZA, 2013).

Este artigo apresenta um estudo comparativo entre a metodologia de otimização *Desirability* descrita por Derringer e Suich (1980) e a utilização do Algoritmo Genético na Otimização de Processos com Múltiplas Respostas.

2. Otimização Multiresposta

2.1. O Método *Desirability*

Uma técnica bastante utilizada na otimização simultânea de várias respostas consiste em transformar os modelos matemáticos de cada uma dessas respostas em funções utilidade individuais para, posteriormente, proceder à otimização de uma função utilidade global (D) que é descrita em termos das funções utilidade individuais. Desse modo, a otimização simultânea de várias respostas pode ser realizada por meio da otimização de uma única função. Derringer e Suich (1980) foram os grandes impulsionadores desta abordagem que serve como uma base de comparação, de fácil interpretação e implementação, entre os métodos numéricos de otimização.

Derringer e Suich (1980) propuseram as funções utilidade individuais apresentadas a seguir, para respostas do tipo Nominal é Melhor (NTB – Nominal The Better), Maior é Melhor (LTB – Larger The Better) e Menor é Melhor (STB - Smaller The Better).

Caso o valor alvo (T) de uma resposta esteja entre um valor máximo (U) e um valor mínimo (L), a resposta é do tipo NTB sendo a função utilidade (d) definida como em (1).

$$d = \begin{cases} \left[\frac{\hat{y} - L}{T - L} \right]^S & L \leq \hat{y} \leq T \\ \left[\frac{\hat{y} - U}{T - U} \right]^R & T \leq \hat{y} \leq U \\ 0 & \hat{y} < L \text{ ou } \hat{y} > U \end{cases} \quad (1)$$

onde R e S são fatores de ponderação, ou pesos, atribuídos.

Caso o valor alvo T seja o valor máximo da função, a resposta é do tipo LTB, sendo a função utilidade d definida como em (2):

$$d = \begin{cases} 0 & \hat{y} < L \\ \left[\frac{\hat{y} - L}{U - L} \right]^R & L \leq \hat{y} \leq T \\ 1 & \hat{y} > U \end{cases} \quad (2)$$

Caso o valor alvo seja o valor mínimo da função, a resposta é do tipo STB sendo a função utilidade d definida como em (3):

$$d = \begin{cases} 0 & \hat{y} > U \\ \left[\frac{\hat{y} - U}{L - U} \right]^R & L \leq \hat{y} \leq U \\ 1 & \hat{y} < L \end{cases} \quad (3)$$

Derringer e Suich (1980) propuseram a otimização das respostas por meio da maximização da função utilidade global dada em (4).

$$D = (d_1 \times d_2 \times d_3 \times \dots \times d_p)^{1/p} \quad (4)$$

onde p corresponde ao número de respostas a serem otimizadas.

Derringer (1994) propôs também a utilização de (5) em substituição à (4) na determinação do valor de D :

$$D = \left(d_1^{w_1} \times d_2^{w_2} \times d_3^{w_3} \times \dots \times d_p^{w_p} \right)^{1/\sum_{i=1}^p w_i} \quad (5)$$

Entretanto, Del Castillo e Montgomery (1993) atentaram para o fato de que basta que uma das funções d tenha um valor inaceitável, por exemplo o valor mínimo ($d = 0$), para que a solução global também se torne inaceitável ($D = 0$).

No método de otimização pela aproximação da distância generalizada são consideradas duas etapas. Na primeira são obtidos os valores ótimos individuais para cada resposta por meio da região obtida experimentalmente. Na segunda, o ótimo global é determinado minimizando-se a função distância p , dada por (6), associada à distância do ótimo global, sendo a variância e a covariância das respostas utilizadas como pesos na função (KHURI e CONLON, 1981).

$$p = \left[(\hat{y}(x) - \theta)^T \cdot \{\text{var}[\hat{y}(x)]\}^{-1} \cdot (\hat{y}(x) - \theta) \right]^{1/2} \quad (6)$$

onde $\hat{y}(x)$ é o vetor de respostas previstas na localização x , $\text{var}[\hat{y}(x)]$ é a variância e covariância da matriz de respostas previstas na localização x e θ é o vetor das respostas alvo.

A equação (6) considera o desvio das respostas alvo e os valores da variância e correlação das respostas. Porém, este método possui como limitação o fato de requerer que o número de respostas e o número de variáveis sejam iguais.

Vining (1998) estendeu a aproximação feita por Khuri e Conlon (1981), levando em consideração os valores da função perda apresentada em (7).

$$\hat{E} = \left[(\hat{y}(x) - \theta)^T \cdot C(\hat{y}(x) - \theta) + \text{trace}[C\{\text{var}[\hat{y}(x)]\}] \right] \quad (7)$$

onde C é uma matriz positiva definida pelos pesos, e os outros termos têm as mesmas definições como em (6). O primeiro termo $\left[(\hat{y}(x) - \theta)^T \cdot C(\hat{y}(x) - \theta) \right]$ representa a penalidade imposta para o desvio de qualquer resposta do respectivo valor alvo, e o segundo termo $\text{trace}[C\{\text{var}[\hat{y}(x)]\}]$ representa a penalidade imposta pela qualidade dos valores previstos.

Em (7) considera-se a correlação entre as respostas e a economia do processo, considerando também a habilidade do modelo na previsão das condições ótimas. Xu *et al.* (2004) colocam como empecilho para a implementação de (7) os fatos da estimativa do parâmetro C ser subjetiva e do cálculo da matriz variância-covariância ser complexo quando as respostas provêm de diferentes formas de modelos.

Del Castillo e Montgomery (1993) citam o Gradiente Reduzido Generalizado (GRG) como sendo um algoritmo de otimização mais eficiente.

Ch'ng *et al.* (2005) propõem que a definição da função utilidade global na forma de uma média aritmética, como em (8), para evitar que o GRG apresente falsos valores ótimos. Isto pode acontecer caso o valor de uma das respostas seja igual ao valor alvo, fazendo com que $(d(\hat{y}_i) - d(T_i)) = 0$ em (8) e, por consequência, D atinja o valor mínimo zero.

$$D = \frac{\left(\sum_{i=1}^p e_i |d(\hat{y}_i) - d(T_i)| \right)}{p} \quad (8)$$

onde $d(\hat{y}_i)$ é a função utilidade da resposta i , $d(T_i)$ é o valor dessa função utilidade no valor alvo, e_i é o fator ponderação da resposta i com $\sum_{i=1}^p e_i = 1$ e p é o número de respostas.

As funções utilidade individuais são definidas por (9).

$$d_i = \frac{2 \cdot \hat{y}_i - (U + L)}{U - L} + 1 = \frac{2 \cdot \hat{y}_i}{U - L} + \frac{-2 \cdot L}{U - L} = m \cdot \hat{y}_i + c \quad (9)$$

com $0 \leq d_i \leq 2$.

Uma revisão mais detalhada sobre métodos de otimização de problemas multiresposta é apresentado em Murphi *et al.* (2005).

2.2. Heurísticas e Meta-heurísticas

Algoritmos heurísticos possuem o objetivo de encontrar soluções para um problema, se destacando principalmente na resolução de problemas de programação inteira. Enquanto os algoritmos exatos garantem uma solução ótima para certos tipos de problemas de otimização, os métodos heurísticos não são capazes provar a otimalidade das suas soluções, porém oferecem soluções aceitáveis, inclusive para problemas complexos e de grande porte, com baixo custo computacional (IGNÍZIO e CAVALIER, 1994).

Meta-heurísticas são procedimentos heurísticos utilizados para guiar outras heurísticas, usualmente de busca local. São utilizadas para avaliar o espaço de soluções além do ótimo local visando, além da exploração das boas características das soluções encontradas, verificar novas regiões promissoras. Para isso utilizam de uma combinação de escolhas aleatórias e do conhecimento do histórico dos resultados anteriores adquiridos para se guiarem e realizar buscas pelo espaço de pesquisa em vizinhanças dentro do espaço de pesquisa, evitando paradas prematuras em ótimos locais (HAMMOUCHE, *et al.* 2010).

2.2.1. Algoritmo Genético (AG)

A Meta-heurística Algoritmo Genético (AG) foi introduzida por Holland (1975). O AG faz parte de um escopo mais abrangente, dos chamados Algoritmos Evolutivos. Nas décadas de 60 e 70, surgiram vários pesquisadores de diferentes pontos dos Estados Unidos e Europa cujas pesquisas convergiam para a ideia de mimetizar o mecanismo de evolução biológica para resolver problemas das mais diversas áreas, em especial a de otimização. Dessas pesquisas resultaram diferentes abordagens algorítmicas, cujos principais representantes são as estratégias evolutivas (RECHENBERG, 1973), a programação evolutiva (FOGEL *et al.*, 1966) e os algoritmos genéticos (HOLLAND, 1975; GOLDBERG, 1989).

Para compreender o funcionamento dos AGs faz-se necessário realizar uma analogia uma explicação sobre a evolução das espécies. Assim, o AG trabalha da seguinte forma:

- a) Inicialmente é gerada uma população formada por um conjunto aleatório de indivíduos, que podem ser vistos como possíveis soluções do problema;
- b) Durante o processo evolutivo, esta população é avaliada, sendo que para cada indivíduo é atribuída uma nota, ou índice, que reflete sua habilidade de adaptação a determinado ambiente;
- c) Uma porcentagem dos indivíduos mais adaptados é mantida, enquanto os outros são descartados;
- d) Os membros mantidos pela seleção podem sofrer modificações em suas características fundamentais por meio de cruzamentos (crossover), mutações ou recombinação genética gerando descendentes para a próxima geração.
- e) Este processo, chamado de reprodução, é repetido até que uma solução satisfatória seja encontrada. Embora possam parecer simplistas do ponto de vista biológico, estes algoritmos são suficientemente complexos para fornecer mecanismos de busca adaptativos poderosos e robustos.

A Figura 1 apresenta um pseudocódigo de um AG clássico.

Figura 1 – Pseudocódigo da meta-heurística AG

Algoritmo AG (μ , p_c , p_m)

Gere a população inicial de tamanho μ

enquanto (critério de parada não for satisfeito) **faça**

 selecione a população de pais

 selecione o operador de recombinação com probabilidade p_c

 selecione o operador de mutação com probabilidade p_m

 avale a população de filhos

 selecione a nova população

fim-enquanto

fim-algoritmo

Fonte: Adaptado Reeves (2003).


3. Método

Visando estimar valores para os parâmetros a fim de minimizar a função objetivo ou função custo, considerou-se as respostas geradas pela técnica do Planejamento de Experimentos de forma aglutinada, que foram incorporadas à função objetivo ou função desejabilidade global obtida pelo método *desirability*.

Para a otimização dos valores dos parâmetros do processo foi utilizado o algoritmo genético, presente na função *optim_ga* do software computacional Scilab. O Scilab é um software computacional livre, de código aberto, utilizado para computação numérica e simulação.

A Figura 2 apresenta o algoritmo utilizado para a otimização utilizando algoritmo genético.

Figura 2 - Representação da metodologia utilizada para a otimização do processo utilizando algoritmo genético (função *optim_ga* do Scilab)



Partindo do algoritmo apresentado na Figura 2, foram realizadas 10 replicações e calculada a média dos resultados obtidos.

Para se proceder a uma comparação entre os métodos numa base equitativa, dado que a função utilidade global não tem a mesma forma em todos eles, o desempenho dos métodos foi avaliado com base em medidas de desempenho apresentadas por Xu *et al.* (2004). Essas medidas, denominadas de Distância Absoluta (DIS) e Desvio Percentual (PER), são definidas em (10) e (11), respectivamente.

$$DIS = \sum_{i=1}^p |\hat{y}_i - T_i| \quad (10)$$

$$PER = \frac{\sum_{i=1}^p \frac{|\hat{y}_i - T_i|}{T_i}}{p} \quad (11)$$

onde T_i corresponde ao valor alvo da resposta $\hat{y}_i$.

Em respostas do tipo LTB e NTB o valor alvo corresponde aos valores de U e L , respectivamente. De acordo com Xu *et al.* (2004), quanto menores forem os valores de DIS e PER, melhor será o desempenho do método, ou seja, mais próximo do valor alvo estarão todas as respostas.

4. Resultados e Discussão

Derringer e Suich (1980) utilizaram o método Desirability para otimizar quatro índices de qualidade de pneus associados a três fatores de controle.

As quatro respostas são $\hat{y}_1$: PICO *abrasion index* (resposta tipo LTB) com as seguintes especificações $\hat{y}_1 \geq 120$ e $T_1 = 170$; $\hat{y}_2$: 200% *modulus* (resposta tipo LTB) com as seguintes especificações $\hat{y}_2 \geq 1000$ e $T_2 = 1300$; $\hat{y}_3$: *elongation at break* (resposta tipo NTB) com as seguintes especificações $400 \leq \hat{y}_3 \leq 600$ e $T_3 = 500$; $\hat{y}_4$: *hardness* (resposta tipo NTB) com as seguintes especificações $60 \leq \hat{y}_4 \leq 75$ e $T_4 = 67,5$. Os três fatores de controle são x_1 : *hydrated sílica level*, x_2 : *silane coupling agent level* e x_3 : *sulfur concentration*. As experiências foram realizadas com base num desenho de compósito central com seis pontos centrais e as equações de regressão das respostas de segunda ordem que foram obtidas são apresentadas em (12) – (15):

$$\hat{y}_1 = 139,12 + 16,49x_1 + 17,88x_2 + 10,91x_3 - 4,01x_1^2 - 3,45x_2^2 - 1,57x_3^2 + 5,13x_1x_2 + 7,13x_1x_3 + 7,88x_2x_3 \quad (12)$$

$$\hat{y}_2 = 126111 + 268,15x_1 + 246,50x_2 + 139,48x_3 - 83,55x_1^2 - 124,79x_2^2 + 199,17x_3^2 + 69,38x_1x_2 + 94,13x_1x_3 + 104,38x_2x_3 \quad (13)$$

$$\hat{y}_3 = 400,38 - 99,67x_1 - 31,40x_2 + 73,92x_3 + 7,93x_1^2 + 17,31x_2^2 + 0,43x_3^2 + 8,75x_1x_2 + 6,25x_1x_3 + 1,25x_2x_3 \quad (14)$$

$$\hat{y}_4 = 68,91 - 1,41x_1 + 4,32x_2 + 1,63x_3 - 1,56x_1^2 + 0,06x_2^2 - 0,32x_3^2 - 1,63x_1x_2 + 0,13x_1x_3 - 0,25x_2x_3 \quad (15)$$

Os resultados obtidos nas dez replicações utilizando a metaheurística algoritmo genético (AG) para otimização deste processo estão sumarizadas na Tabela 1.

Tabela 1 – Parâmetros otimizados pela metaheurística algoritmo genético (AG)

Replicata	x_1	x_2	x_3	y_1	y_2	y_3	y_4
1	-0,2071	0,0505	-1,0446	124,3906	1299,9508	498,7022	67,4939
2	-0,2151	0,0486	-1,0457	124,2718	1298,3700	499,7273	67,5000
3	-0,2195	0,0556	-1,0460	124,2764	1298,3211	500,0019	67,5442
4	-0,2103	0,0504	-1,0452	124,3467	1299,4324	499,1001	67,4991
5	-0,2177	0,0453	-1,0412	124,2758	1296,1444	499,7689	67,5000
6	-0,2177	0,0583	-1,0451	124,3311	1298,7393	499,6406	67,5550
7	-0,2178	0,0520	-1,0469	124,2545	1298,5479	500,0000	67,5205
8	-0,2163	0,0662	-1,0423	124,4485	1299,0660	499,0130	67,5977
9	-0,2148	0,0389	-1,0455	124,1977	1297,3008	500,0000	67,4519
10	-0,2092	0,0560	-1,0438	124,4231	1299,8800	498,6939	67,5277

Analisando a Tabela 1 é possível observar que não há grandes variações entre os resultados obtidos, a variação encontrada nas respostas pode ser explicada pelo fato que ao iniciar o processo de busca, o AG gera uma população inicial por meio de números aleatórios o que influencia em sua resposta final. Na Tabela 2 encontram-se os valores obtidos para média, desvio-padrão e coeficiente de variação da população de resultados apresentados na Tabela 1.

Tabela 2 – Resultados de estatística descritiva para a população de respostas obtidos pelo algoritmo genético

	x_1	x_2	x_3	y_1	y_2	y_3	y_4
Média	-0,2146	0,0522	-1,0446	124,3216	1298,5753	499,4648	67,5190
Desvio-Padrão	0,0040	0,0071	0,0017	0,0764	1,1062	0,5066	0,0381
Coefficiente de Variação (%)	1,8674	13,6195	0,1604	0,0614	0,0852	0,1014	0,0564

Observando os valores do coeficiente de variação dos resultados, pode-se concluir que a variação embutida nas replicatas do AG é baixa. A exceção fica por conta da variável x_2 que apresenta um coeficiente de variação de 13,6195 %, o que pode ser explicado pelos baixos valores de média e desvio padrão.

Após a aquisição dos dados médios oriundos do AG, foi realizada a comparação com o método *Desirability* proposto por Derringer e Suich (1980), os resultados obtidos estão sumarizados na Tabela 3.

Tabela 3 – Comparação do Resultados obtidos pelo AG

Variável	Método	
	Desirability	AG
x_1	- 0,050	- 0,2146
x_2	0,145	0,0522
x_3	- 0,868	- 1,0446
$\hat{y}_1$	129,50	124,32
$\hat{y}_2$	1300,00	1298,58
$\hat{y}_3$	465,70	499,46
$\hat{y}_4$	68,00	67,52
DIS	75,30	47,68
PER (%)	7,86	6,78

Nota-se que nos dois fatores estudados, Distância Absoluta (DIS) e Distância Percentual (PER), o método proposto neste trabalho (AG) apresenta os melhores resultados em comparação com o método *Desirability*.

Pode-se observar na Tabela 3 que o AG obtém a menor Distância Percentual (PER) quando comparado ao método *Desirability*, demonstrando que o AG tem a vantagem de otimizar todas as respostas de maneira equilibrada.

4. Conclusão

Mesmo sendo um método estocástico o Algoritmo Genético demonstra convergir sempre para mesma área da função objetivo. Tal convergência não pode ser encarada como uma otimização e sim como uma melhoria, uma vez que o método não testa todas as soluções possíveis.

O resultado obtido sugere a aplicação do Algoritmo Genético quando se pretender otimizar múltiplas respostas, em particular quando essas respostas são modeladas por equações com termos quadráticos independentemente do número de termos que possam conter, do tipo de respostas e do número de variáveis. Porém, deve-se proceder uma maior quantidade de testes com outros problemas com múltiplas respostas a fim de se confirmar este comportamento.

REFERÊNCIAS

- CARLILE, W. Matthew; MONTGOMERY, Douglas C.. e RUNGER, George C.. Optimization Problems and Methods in Quality Control and Improvement. **Journal of Quality Technology**, v. 32, n.1, p. 1-17, 2000.
- CH'NG, C.; QUAH, S.; LOW, H., A New Approach for Multiple-Response Optimization. **Quality Engineering**, v. 17, n. 4, pp. 621-626, 2005.
- COSTA, NUNO; PIRES, RAMOS. Respostas múltiplas - Uma abordagem para melhorar os processos e os produtos, 8º Congresso Ibero-Americano de Engenharia Mecânica, Cusco, pp. 1631-1639, 2007.
- DEL CASTILLO, Enrique, and MONTGOMERY, Douglas C., A Nonlinear Programming Solution to the Dual Response Problem. **Journal of Quality Technology**, 25, n. 4, pp. 199-204, 1993.
- DERRINGER, George, A Balancing Act: Optimizing a Product's Properties. **Quality Progress**, pp. 51-58, 1994.
- DERRINGER, George e SUICH, Ronald, Simultaneous Optimization of Several Response Variables, **Journal of Quality Technology**, v. 12, n. 4, pp. 214-219, 1980.
- FOGEL, L. J.; OWENS, A. J.; WALSH, M. J. Artificial intelligence through simulated evolution. New York: John Wiley, 1966. 162 p.
- GOLDBERG, D. E. Genetic algorithms in Search: optimization and machine learning. Addison-Wesley: Berkeley, 1989. 223 p.

- HAMMOUCHE, K., DIAF, M. e SIARRY, P., A Comparative Study of Various Meta-Heuristic Techniques Applied to the Multilevel Thresholding Problem., **Engineering Applications of Artificial Intelligence**, v. 23, pp 676-688, 2010.
- HOLLAND, J. H. Adaptation in natural and artificial systems. Michigan: University of Michigan Press, 1975. 211 p.
- IGNIZIO, J.P. & CAVALIER T.M., Linear Programming, Englewood Cliffs: Prentice Hall, 1994, 666 p.
- KHURI A. I. e CONLON M., Simultaneous Optimization of Multiple Responses Represented by Polynomial Regression Functions. **Technometrics**, v. 23, n. 4, pp. 363-375, 1981.
- MURPHI, T.E., TSUI, K. e ALLEN, J.K., A Review of Robust Design Methods for Multiple Response, **Research in Engineering Design**, v. 15, pp. 201-215, 2005
- PIAGNATIELLO, J.J., Strategies for Robust Multiresponse Quality Engineering. **IIIE Transactions**, v. 25, pp 5-15, 1993.
- RECHENBERG, I. Evolutionsstrategie: optimierung technischer systeme nach prinzipien der biologischen evolution. Stuttgart, 1973.
- REEVES, C. Genetic algorithms. In: GLOVER, F.; KOCHENBERGER, G. A. (Ed.). Handbook of Metaheuristics. New York: Springer, 2003, (International Series in Operations Research & Management Science, v. 57). p. 55–82.
- SOUSA, MARCELO DO NASCIMENTO. Influência das Propriedades Mecânicas das Ligas de Alumínio na Usinabilidade – Foco no Grau de Recalque, na Dimensão da Zona de Fluxo e na Microdureza dos Cavacos, Tese de Doutorado, Universidade Federal de Uberlândia, 138 p., 2013.
- VINING G., A Compromise Approach to Multiresponse Optimization. **Journal of Quality Technology**, v. 30, n. 4, pp. 309-313, 1998.
- XU, Kay.; LIN, Denis K. J.; TANG, Loon-Ching. e XIE, Mim, Multiresponse Systems Optimization Using a Goal Attainment Approach. **IIIE Transactions**, v. 36, n. 5, pp. 433-445, maio 2004.
- WU, C. F. Jeff e HAMADA, Michael S., “Experiments: Planning, Analysis, and Parameter Design Optimization.” Wiley-Interscience, New York, 2000.